

# Débruitage de la matrice interspectrale pour l'étude des sources aéroacoustiques

A. Dinsenmeyer<sup>1,2</sup>, Q. Leclère<sup>1</sup>, J. Antoni<sup>1</sup> et E. Julliard<sup>3</sup>

<sup>1</sup> Laboratoire Vibrations Acoustique

<sup>2</sup> Laboratoire de Mécanique des Fluides et d'Acoustique

Lyon, France

<sup>3</sup> Airbus, Toulouse

Journée CeLyA – Mars 2019

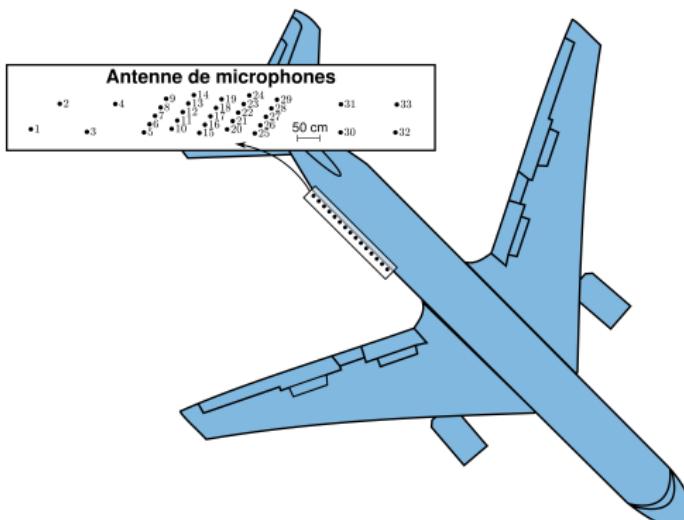


# Contexte

- ▶ **Mesures bruitées** : Extérieur venté, soufflerie, milieu sous-marin, etc.

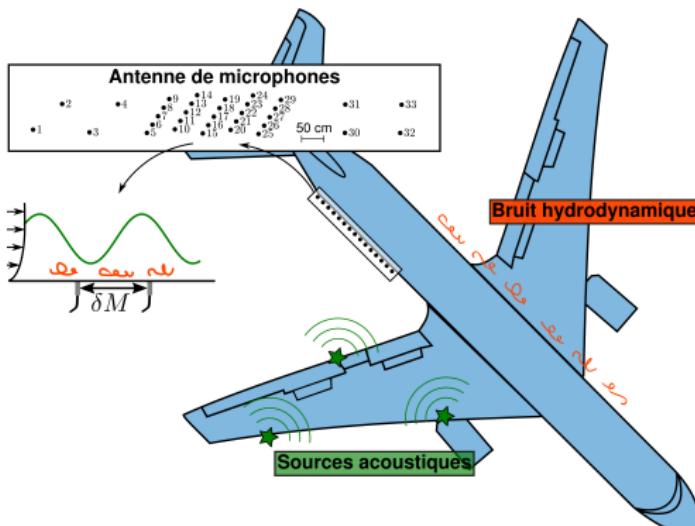
# Contexte

- ▶ **Mesures bruitées** : Extérieur venté, soufflerie, milieu sous-marin, etc.
- ▶ **Contexte industriel** : design moteur et profil



# Contexte

- ▶ **Mesures bruitées** : Extérieur venté, soufflerie, milieu sous-marin, etc.
  - ▶ **Contexte industriel** : design moteur et profil
  - ▶ 2 types de fluctuations de pression :
    - les sources acoustiques (**signal**)
    - la turbulence de l'écoulement (**bruit**)
- } SNR très faible voire négatif



# Contexte

**Comment séparer la contribution des sources acoustiques et le bruit de couche limite turbulente ?**

## Les méthodes existantes

- ▶ méthodes expérimentales : mousse, kevlar, microphones déportés,...
- ▶ soustraction du bruit de fond
- ▶ filtrage en nombres d'onde
- ▶ si les mesures sont suffisamment longues : post-traitement (ex : problème inverse)

# Contexte

**Comment séparer la contribution des sources acoustiques et le bruit de couche limite turbulente ?**

## Les méthodes existantes

- ▶ méthodes expérimentales : mousse, kevlar, microphones déportés,...
- ▶ soustraction du bruit de fond
- ▶ filtrage en nombres d'onde
- ▶ si les mesures sont suffisamment longues : post-traitement (ex : problème inverse)

## Méthodes proposées

- ▶ Résolution d'un problème inverse : Décomposition matricielle
- ▶ Utilisation de signaux de référence non-bruités

# Plan de la présentation

**1** La matrice interspectrale

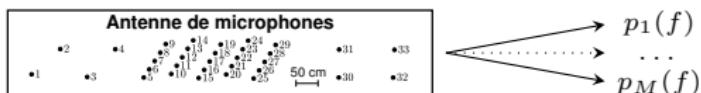
**2** Analyse Factorielle Probabiliste

**3** Débruitage référencé

**4** Application en cas réel

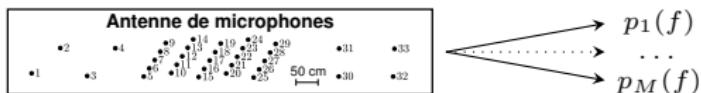
# La matrice interspectrale

Spectres moyennés (processus stationnaire)



# La matrice interspectrale

Spectres moyennés (processus stationnaire)

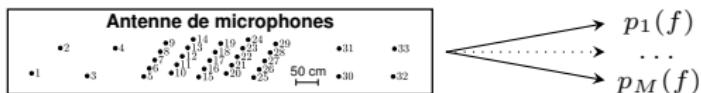


$$\mathbf{S}_{pp}(f)$$

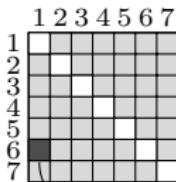
	1	2	3	4	5	6	7
1	■						
2		■					
3			■				
4				■			
5					■		
6						■	
7							■

# La matrice interspectrale

Spectres moyennés (processus stationnaire)



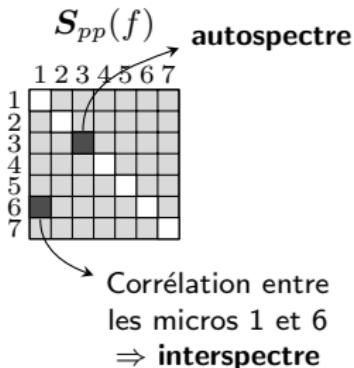
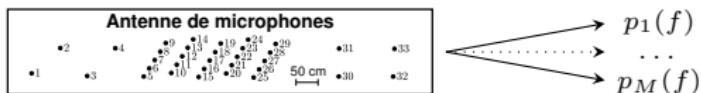
$$\mathbf{S}_{pp}(f)$$



Corrélation entre  
les micros 1 et 6  
 $\Rightarrow$  **interspectre**

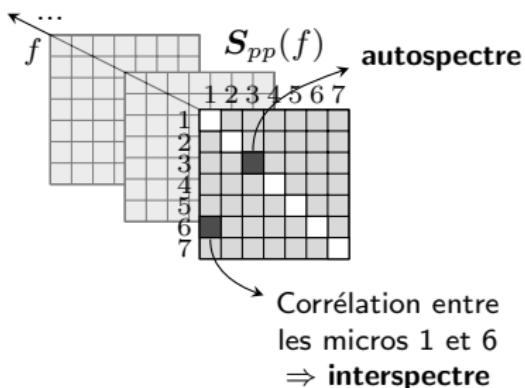
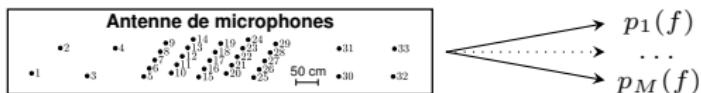
# La matrice interspectrale

Spectres moyennés (processus stationnaire)

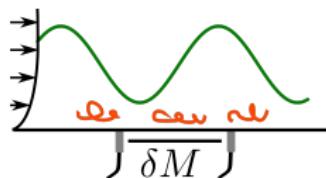


# La matrice interspectrale

Spectres moyennés (processus stationnaire)



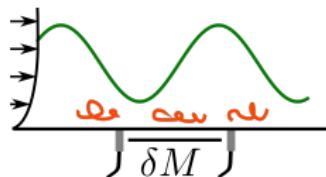
# Propriétés de la MI



Pour  $i = 1, \dots, I$  moyennes

$$\underbrace{\mathbf{p}_i}_{\text{spectres mesurés}} = \underbrace{\mathbf{a}_i}_{\text{sources acoustiques}} + \underbrace{\mathbf{n}_i}_{\text{bruit à retirer}}$$

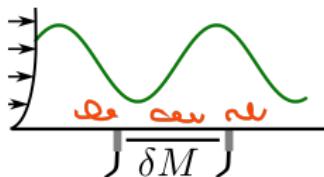
# Propriétés de la MI



MI moyennées :

$$\underbrace{S_{pp}}_{\text{MI mesurée}} = \underbrace{S_{aa}}_{\text{sources acoustiques}} + \underbrace{S_{nn}}_{\text{bruit à retirer}} + \underbrace{S_{an} + S_{na}}_{\text{termes croisés}}$$

# Propriétés de la MI



MI moyennées :

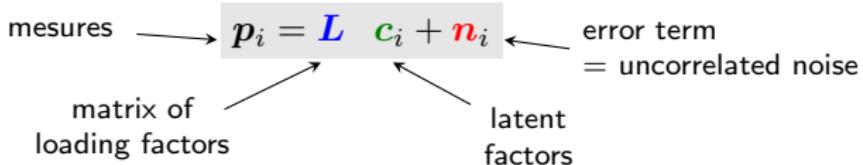
$$\underbrace{S_{pp}}_{\text{MI mesurée}} = \underbrace{S_{aa}}_{\text{sources acoustiques}} + \underbrace{\cancel{S_{nn}}}_{\text{bruit à retirer} \approx \text{diagonale}} + \underbrace{\cancel{S_{an}} + \cancel{S_{na}}}_{\text{termes croisés}} \rightarrow 0$$



- ▶ Signal **acoustique corrélé** : **MI à rang réduit**  
peu des monopoles équivalents
- ▶ **Bruit** faiblement corrélé : **MI diagonale**

# Analyse Factorielle Probabiliste – Modèle statistique

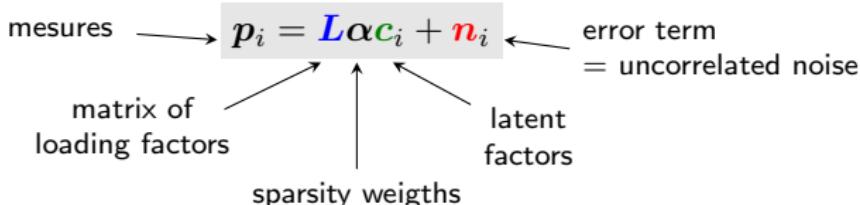
## ► Latent variable model



- Capture dominant correlation with fewer parameters (close to PCA)  
→ MI à rang réduit
- Extract anisotropic noise

# Analyse Factorielle Probabiliste – Modèle statistique

## ► Latent variable model



- Capture dominant correlation with fewer parameters (close to PCA)
  - MI à rang réduit
- Extract anisotropic noise
- Enforced sparsity to reduce the number of significant factors
  - Data compression

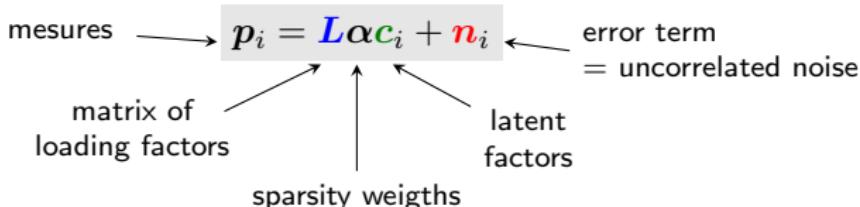
## ► Bayesian framework: See parameters as random variables

$\mathbf{L} \sim \mathcal{N}_{\mathbb{C}}(0, \lceil \frac{1}{K} \rceil)$	$\mathbf{c}_i \sim \mathcal{N}_{\mathbb{C}}(0, \lceil \gamma^2 \rceil)$	$\mathbf{n}_i \sim \mathcal{N}_{\mathbb{C}}(0, \lceil \sigma_n^2 \rceil)$	$\boldsymbol{\alpha} \sim \mathcal{E}(a_{\alpha})$
--	---	---	--

+ hyperparameters :  $\gamma^2, \sigma^2 \sim \mathcal{IG}(a_{\gamma, \sigma}, b_{\gamma, \sigma})$

# Analyse Factorielle Probabiliste – Modèle statistique

## ► Latent variable model



- Capture dominant correlation with fewer parameters (close to PCA)  
→ MI à rang réduit
- Extract anisotropic noise
- Enforced sparsity to reduce the number of significant factors  
→ Data compression

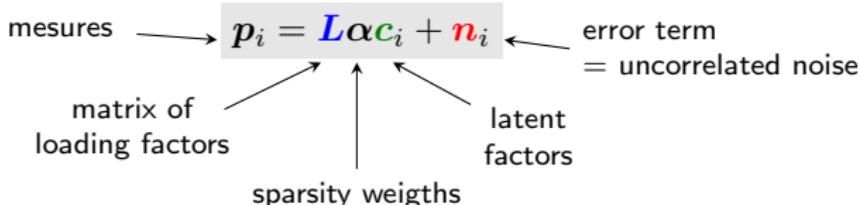
## ► Bayesian framework: See parameters as random variables

$\mathbf{L} \sim \mathcal{N}_{\mathbb{C}}(0, \lceil \frac{1}{K} \rfloor)$	$\mathbf{c}_i \sim \mathcal{N}_{\mathbb{C}}(0, \lceil \gamma^2 \rfloor)$	$\mathbf{n}_i \sim \mathcal{N}_{\mathbb{C}}(0, \lceil \sigma_n^2 \rfloor)$	$\boldsymbol{\alpha} \sim \mathcal{E}(a_{\alpha})$
---	--	--	--

+ hyperparameters :  $\gamma^2, \sigma^2 \sim \mathcal{IG}(a_{\gamma, \sigma}, b_{\gamma, \sigma})$

# Analyse Factorielle Probabiliste – Modèle statistique

## ► Latent variable model



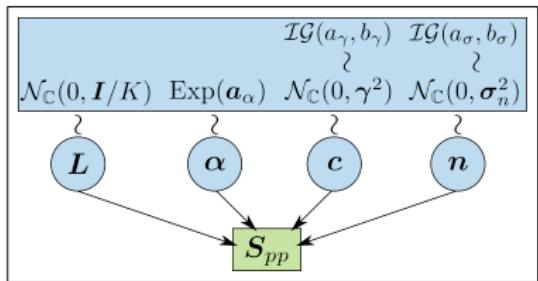
- Capture dominant correlation with fewer parameters (close to PCA)
  - MI à rang réduit
- Extract anisotropic noise
- Enforced sparsity to reduce the number of significant factors
  - Data compression

## ► Bayesian framework: See parameters as random variables

$\mathbf{L} \sim \mathcal{N}_{\mathbb{C}}(0, \lceil \frac{1}{K} \rceil)$	$\mathbf{c}_i \sim \mathcal{N}_{\mathbb{C}}(0, \lceil \gamma^2 \rceil)$	$\mathbf{n}_i \sim \mathcal{N}_{\mathbb{C}}(0, \lceil \sigma_n^2 \rceil)$	$\boldsymbol{\alpha} \sim \mathcal{E}(a_{\alpha})$
--	---	---	--

+ hyperparameters :  $\gamma^2, \sigma^2 \sim \mathcal{IG}(a_{\gamma, \sigma}, b_{\gamma, \sigma})$

# Analyse Factorielle Probabiliste – Optimisation



**Parametric model:**  $\mathcal{M}(\theta)$   
with  $\theta = \{L, \alpha, c, n, a_{\gamma, \alpha, \sigma}, b_{\gamma, \alpha, \sigma}\}$

**Optimization step :**

$$\theta = \underset{\theta}{\operatorname{argmax}} \underbrace{p(\theta | S_{yy})}_{\text{fitness function}}$$

The fitness function is the posterior probability  $\rightarrow$  has no close form  
 $\hookrightarrow$  approximation with numerical methods

# Analyse Factorielle Probabiliste – Optimisation

## Maximisation de la distribution a posteriori

- ↪ Trouver les paramètres optimaux qui expliquent au mieux les données
- ↪ Méthode : l'échantillonneur de Gibbs

# Analyse Factorielle Probabiliste – Optimisation

## Maximisation de la distribution a posteriori

- ↪ Trouver les paramètres optimaux qui expliquent au mieux les données
- ↪ Méthode : l'échantillonneur de Gibbs

# Analyse Factorielle Probabiliste – Optimisation

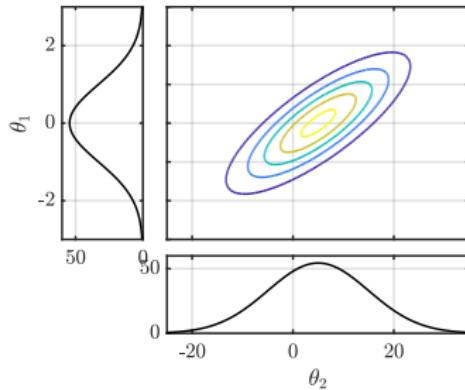
## Maximisation de la distribution a posteriori

- ↪ Trouver les paramètres optimaux qui expliquent au mieux les données
- ↪ Méthode : l'échantillonneur de Gibbs

# Analyse Factorielle Probabiliste – Optimisation

## Maximisation de la distribution a posteriori

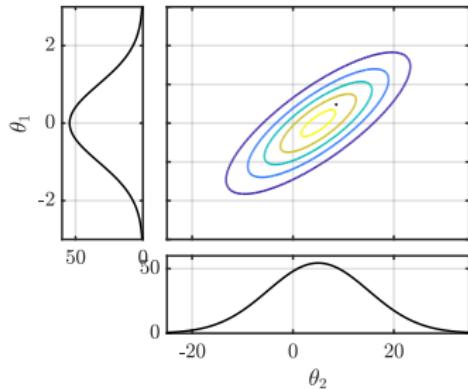
- ↪ Trouver les paramètres optimaux qui expliquent au mieux les données
- ↪ Méthode : l'échantillonneur de Gibbs



# Analyse Factorielle Probabiliste – Optimisation

## Maximisation de la distribution a posteriori

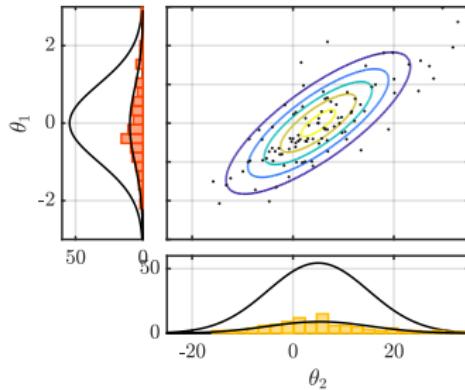
- ↪ Trouver les paramètres optimaux qui expliquent au mieux les données
- ↪ Méthode : l'échantillonneur de Gibbs



# Analyse Factorielle Probabiliste – Optimisation

## Maximisation de la distribution a posteriori

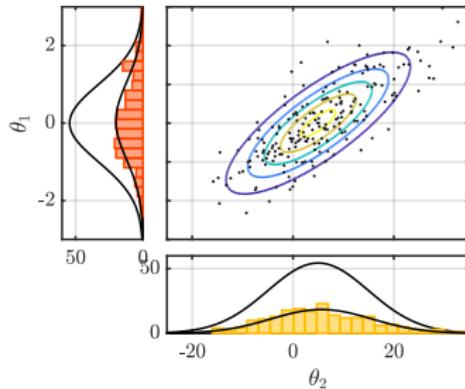
- ↪ Trouver les paramètres optimaux qui expliquent au mieux les données
- ↪ Méthode : l'échantillonneur de Gibbs



# Analyse Factorielle Probabiliste – Optimisation

## Maximisation de la distribution a posteriori

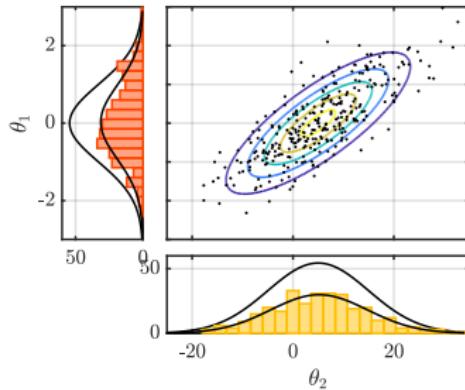
- ↪ Trouver les paramètres optimaux qui expliquent au mieux les données
- ↪ Méthode : l'échantillonneur de Gibbs



# Analyse Factorielle Probabiliste – Optimisation

## Maximisation de la distribution a posteriori

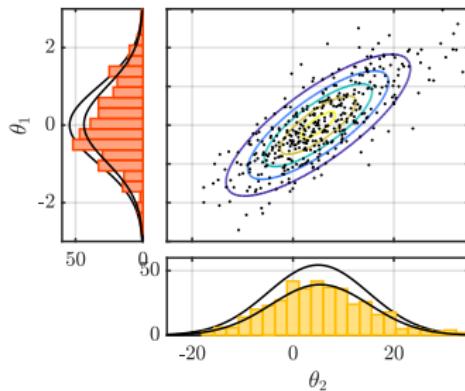
- ↪ Trouver les paramètres optimaux qui expliquent au mieux les données
- ↪ Méthode : l'échantillonneur de Gibbs



# Analyse Factorielle Probabiliste – Optimisation

## Maximisation de la distribution a posteriori

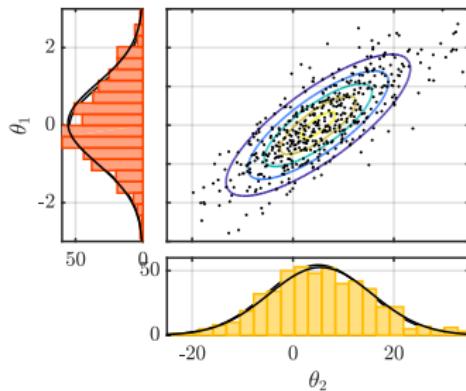
- ↪ Trouver les paramètres optimaux qui expliquent au mieux les données
- ↪ Méthode : l'échantillonneur de Gibbs



# Analyse Factorielle Probabiliste – Optimisation

## Maximisation de la distribution a posteriori

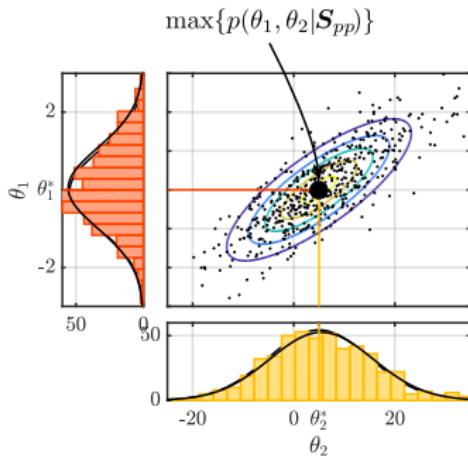
- ↪ Trouver les paramètres optimaux qui expliquent au mieux les données
- ↪ Méthode : l'échantillonneur de Gibbs



# Analyse Factorielle Probabiliste – Optimisation

## Maximisation de la distribution a posteriori

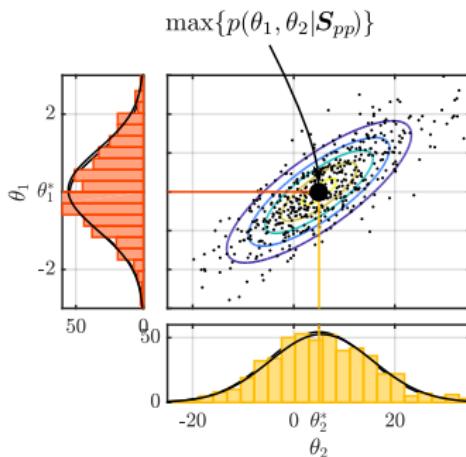
- ↪ Trouver les paramètres optimaux qui expliquent au mieux les données
- ↪ Méthode : l'échantillonneur de Gibbs



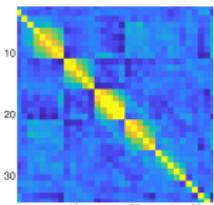
# Analyse Factorielle Probabiliste – Optimisation

## Maximisation de la distribution a posteriori

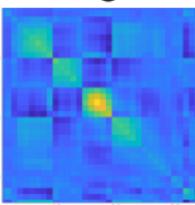
- ↪ Trouver les paramètres optimaux qui expliquent au mieux les données
- ↪ Méthode : l'échantillonneur de Gibbs



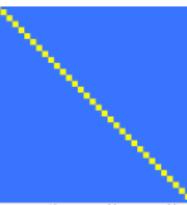
MI mesurée



MI signal



MI bruit



Exemple de  
mesures en vol



- Gibbs sampler:

- intègre les connaissances a priori
- fournit un intervalle de crédibilité
- optimisation globale

- PFA:

- la MI conserve un sens physique
- compresse les données
- aucun paramètre à régler
- modèle flexible
- possibilité de prendre en compte plusieurs configurations



- Gibbs sampler:

- intègre les connaissances a priori
- fournit un intervalle de crédibilité
- optimisation globale



- PFA:

- la MI conserve un sens physique
- compresse les données
- aucun paramètre à régler
- modèle flexible
- possibilité de prendre en compte plusieurs configurations

- Sensibilité au choix des a priori not. quand le problème est mal conditionné
- Coûts de calcul élevés

## Débruitage référencé

*Hypothèse : le bruit extérieur de couche limite n'est pas présent sur les micros de référence*

- |     |  |   |                      |
|-----|--|---|----------------------|
| $y$ | : signaux à débruiter  | } | acquis simultanément |
| $r$ | : signaux de référence non-bruités<br>(ex : intérieur de cabine) |   |                      |
| $a$ | : signaux débruités  |   |                      |

$$S_{aa} = S_{pr} S_{rr}^{-1} S_{rp} \rightarrow$$

Généralisation des spectres cohérents

# Débruitage référencé

*Hypothèse : le bruit extérieur de couche limite n'est pas présent sur les micros de référence*

- |  |   |                      |
|--|---|----------------------|
| $y$ : signaux à débruiter<br>$r$ : signaux de référence non-bruités<br>(ex : intérieur de cabine)<br>$a$ : signaux débruités | } | acquis simultanément |
|--|---|----------------------|

$$S_{aa} = S_{pr} S_{rr}^{-1} S_{rp}$$

Généralisation des spectres cohérents



- ▶ Simple à implémenter
- ▶ Faible coût de calcul

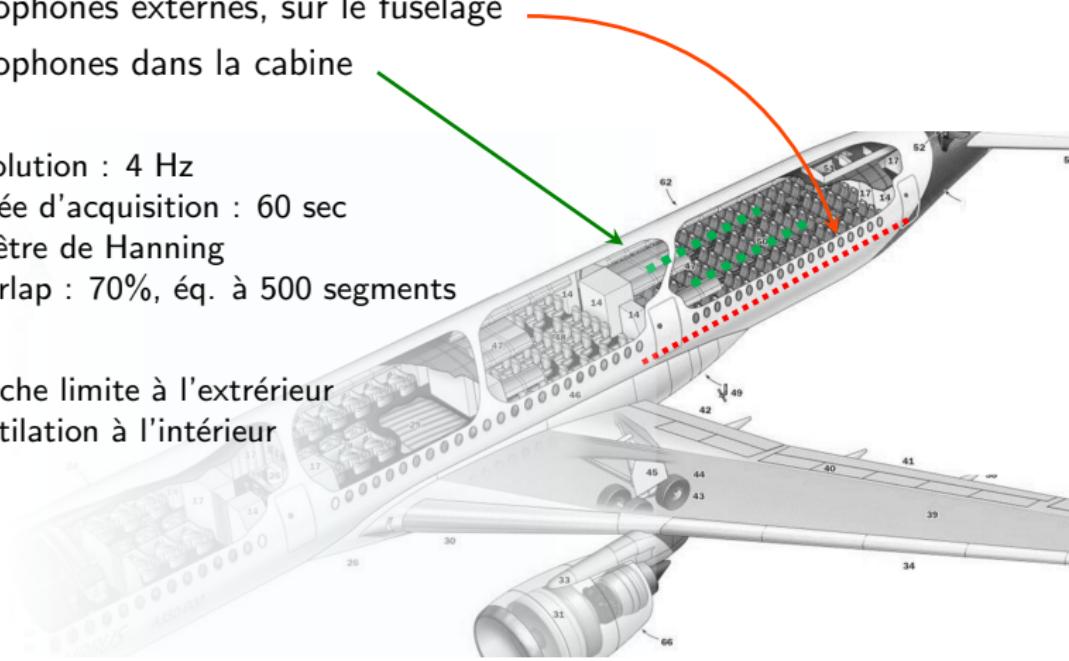


- ▶ signaux de référence : non bruités (ou bruit décorrélatif)
- ▶ nécessite des mesures simultanées supplémentaires
- ▶ les seuils de cohérence dépendent
  - de la longueur des signaux
  - du nombre de références

## Application en cas réel

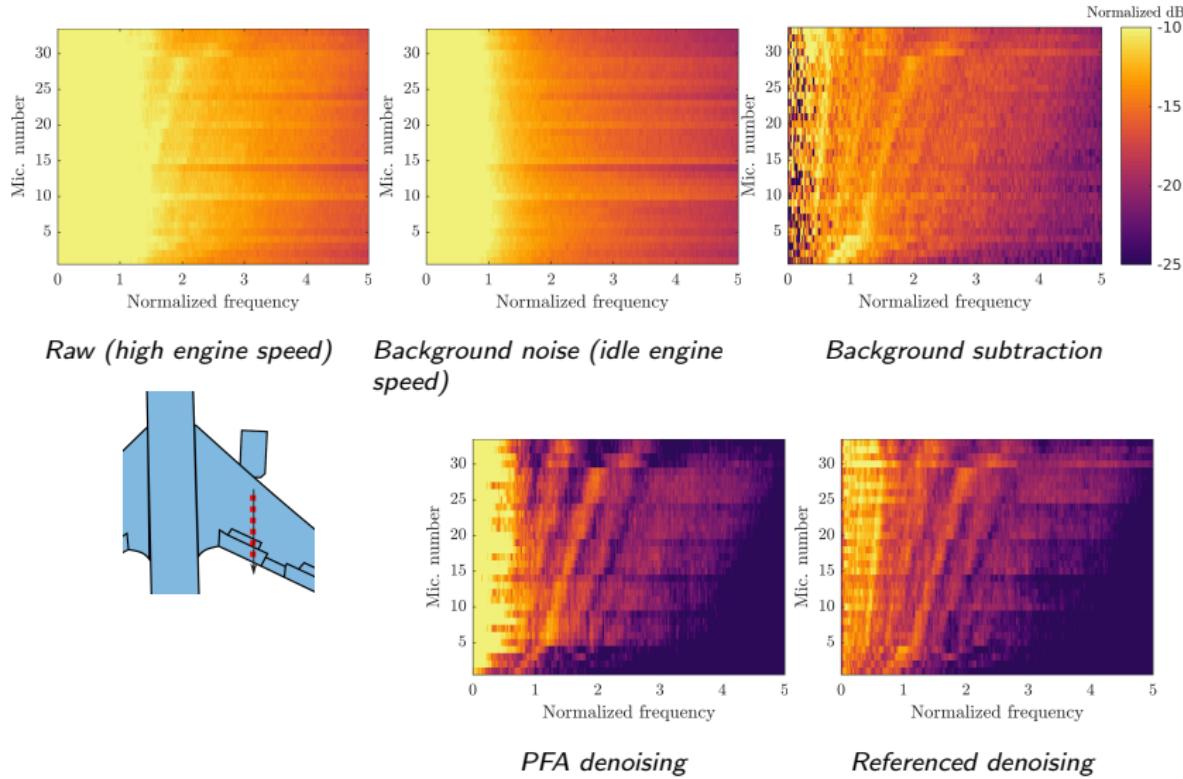
- ▶ Essais en vol
- ▶ Conditions réalistes de vol : Mach 0.85
- ▶ 6 régimes moteur dont 1 bruit de fond
- ▶ 35 microphones externes, sur le fuselage
- ▶ 14 microphones dans la cabine
- ▶ MI :
  - résolution : 4 Hz
  - durée d'acquisition : 60 sec
  - fenêtre de Hanning
  - overlap : 70%, éq. à 500 segments

- ▶ Bruits :
  - couche limite à l'extérieur
  - ventilation à l'intérieur



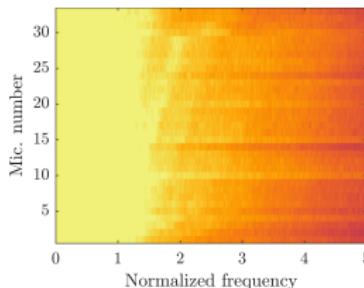
# Application en cas réel

## Autospectres zoomés dans la zone BBSAN

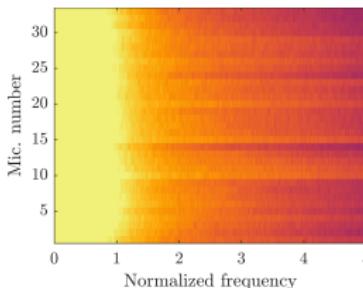


# Application en cas réel

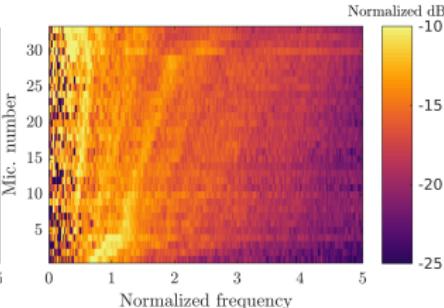
## Autospectres zoomés dans la zone BBSAN



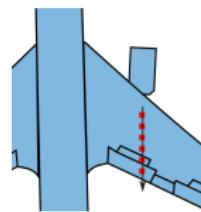
*Raw (high engine speed)*



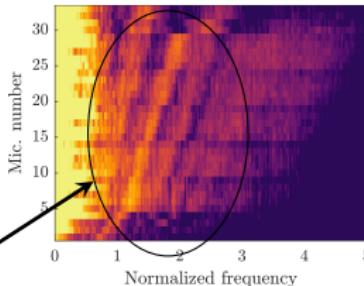
*Background noise (idle engine speed)*



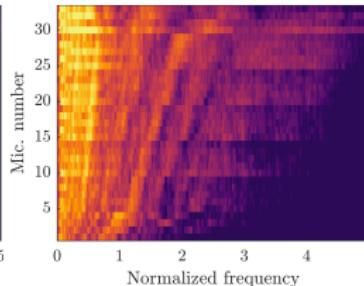
*Background subtraction*



figures d'interférences :  
bruit de chocs large bande

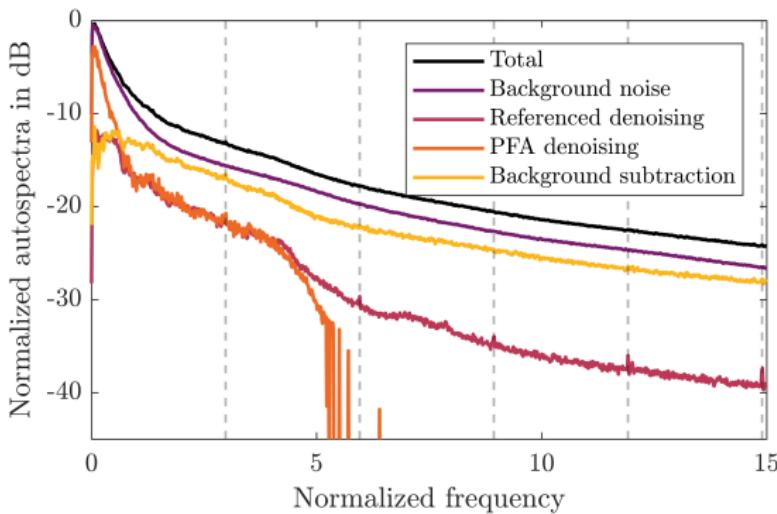


*PFA denoising*



*Referenced denoising*

## Application en cas réel

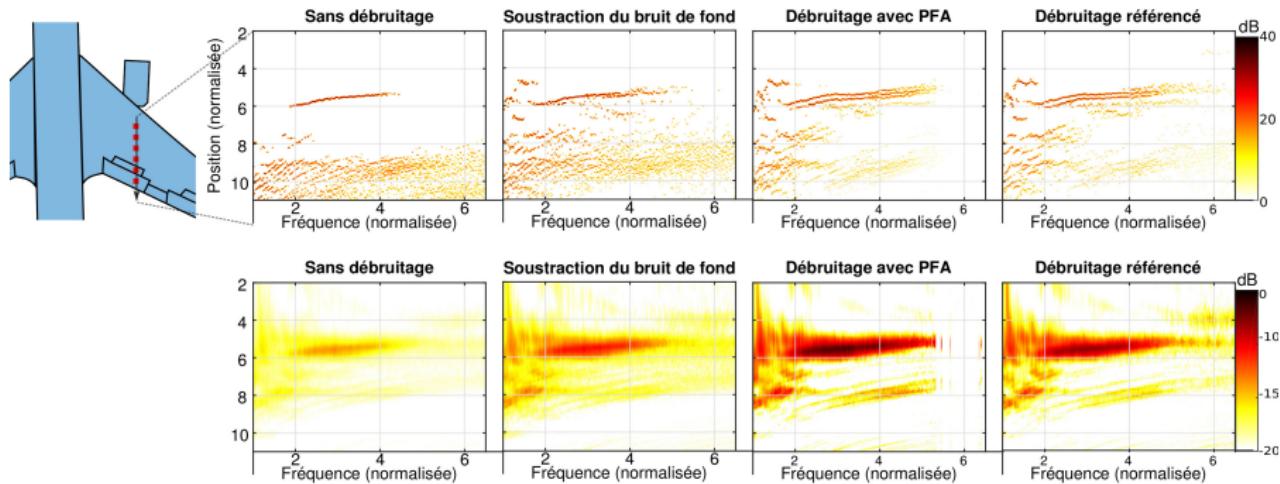


- Dynamique améliorée de 10-15 dB
- PFA :
  - Peu de bruit extrait à très basses fréquences → bruit corrélé
  - Pas de signal à moyennes fréquences → modèle/priors à adapter
- PFA et méthode référencée concordantes en BF

# Application en cas réel – Imagerie

## Méthode inverse

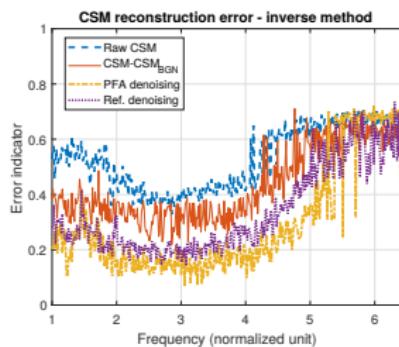
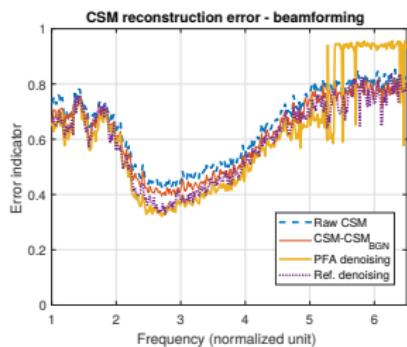
Iterative Reweighted Least Squares,  $p = 0$  + régularisation bayésienne



## Formation de voie

# Application en cas réel – Imagerie

$$\text{Erreur} = \frac{\|S_{aa}^{\text{débruitage}} - S_{aa}^{\text{repropagé}}\|_1}{\|S_{aa}^{\text{débruitage}}\|_1 + \|S_{aa}^{\text{repropagé}}\|_1}$$



## Conclusions et perspectives

- ▶ Débruitage avec différentes approches, mais résultats concordants
- ▶ Amélioration des performances d'imagerie
  - dynamique
  - localisation de sources corrélées
- ▶ Corrections pour PFA :
  - augmenter la robustesse de l'échantillonneur
  - adapter le modèle statistique (meilleur contrôle de la parcimonie)
  - prendre en compte la corrélation du bruit en BF

---

*This work was performed in the framework of Clean Sky 2 Joint Undertaking, European Union (EU), Horizon 2020, CS2-RIA, ADAPT project, Grant agreement no 754881.*